

基于自适应不确定性集合与 PCA 归一化残差的 Mag 7 稳健交易策略

Tiatian ZHANG

2026 年 1 月 19 日

Strategy	Wealth	Mathematical Form / Logic	Primary Constraints
IPMO	1.5043	$\max_w \sum_{t=0}^H [(\mu_t \cdot \text{Conf})^T w_t - \text{Cost}_{TC} - \text{Risk}]$	$\ w_0 - w_p\ _1 \leq 15\%, w \leq 0.05$
Robust	1.3980	$\max_w \left(\frac{\mu}{1+\lambda\sigma_m} \right)^T w - \gamma \sum (1 + \sigma_{m,i}^2) w_i^2$	$\ w - w_p\ _1 \leq 15\%, \sum w = 1$
Hybrid 3D	1.2825	$\max_w \underbrace{\mu_{robust}^T w}_{\text{Signal}} - \underbrace{\gamma \ w\ _2^2}_{\text{Variance}} - \underbrace{\gamma_c \ \beta^T w\ _2^2}_{\text{Connectivity}}$	$\ w - w_p\ _1 \leq 15\%, \text{Factor Caps}$
3D Front	1.2777	$\max_w \mu^T w - \gamma_{conn} \ \beta^T w\ _2^2$	Eigen-Penalty on PCA Factors
Alpha Wt	1.1978	$w_i = \text{clip}(\frac{\alpha_i}{\sum \alpha}, 0, 0.05) \rightarrow \text{Rebalance Limit}$	Step-wise Turnover Smoothing

Table 1: Detailed Comparison of Portfolio Optimization Frameworks

1 问题背景：论文两阶段结构

IPMO 论文采用典型的两阶段框架：

(第一步：预测层)

$$\min_{\theta} \mathbb{E} \ell(\hat{y}(\theta), y) \Rightarrow \hat{y}_t \approx \mathbb{E}[y_t | \mathcal{F}_t]. \quad (1)$$

即通过最小化预测误差，学习条件期望收益。

(第二步：决策层)

$$\min_z \sum_{k=1}^H \left(\frac{\gamma}{2} z_k^\top \Sigma z_k - \hat{y}_k^\top z_k + \lambda \|z_k - z_{k-1}\|_1 \right). \quad (2)$$

该问题在均值-方差框架下，引入 L_1 换手惩罚以控制调仓。

2 第一步等价性：预测层的内生性

工程实现中，并未显式求解预测误差最小化问题，而是直接构造了带不确定性修正的有效预测信号：

$$\mu_t^{\text{eff}} = \mu_t \odot \frac{1}{1 + \sigma_t}. \quad (3)$$

其中 σ_t 表示模型分歧或预测不确定性。

在贝叶斯或稳健统计框架下，若均值估计存在方差 σ_t ，则后验期望必然发生收缩 (shrinkage)：

$$\mathbb{E}[y_t | \mathcal{F}_t, \text{model risk}] = \frac{\tau}{\tau + \sigma_t} \mu_t. \quad (4)$$

该结构与实现中的 $\mu_t / (1 + \sigma_t)$ 在数学形式上完全一致。

结论： 论文第一步学习的是 $\mathbb{E}[y_t]$ ，工程实现使用的是

$$\mathbb{E}[y_t \mid \text{model risk}],$$

即预测层被内生化为决策目标函数。这属于典型的 **decision-focused learning** 结构。

3 第二步等价性：决策层的结构保持

工程实现所求解的问题为：

$$\max_{\{w_t\}} \sum_t \left((\mu_t^{\text{eff}})^\top w_t - \frac{\gamma}{2} w_t^\top \Sigma w_t - \eta \|w_t - w_{t-1}\|_2^2 \right). \quad (5)$$

逐项对齐：

论文 IPMO	工程实现	数学含义
$-\hat{y}^\top z$	$+(\mu^{\text{eff}})^\top w$	收益项
$\frac{\gamma}{2} z^\top \Sigma z$	$\frac{\gamma}{2} w^\top \Sigma w$	风险项
$\lambda \ \Delta z\ _1$	$\eta \ \Delta w\ _2^2$	换手摩擦

两者在结构上完全一致：

- 多周期路径优化
- 均值-方差风险结构
- 调仓依赖
- 显式摩擦项

唯一差异为正则项替换：

$$\|\Delta z\|_1 \rightarrow \|\Delta w\|_2^2. \quad (6)$$

在变分法与最优控制理论中，两者同属耗散势（dissipation potential），分别对应：

- L_1 ：干摩擦（非光滑，一阶系统）
- L_2^2 ：粘性阻尼（光滑，二阶系统）

因此工程实现仍然求解同一效用最大化问题，只是采用了更稳定的物理摩擦定律。

4 模型等价性总结

论文 IPMO 属于：

带风险项与换手成本的离散时间最优控制问题。

工程实现对应：

带风险项与换手成本的离散时间最优控制问题（平滑稳定化版本）。

两者本质上都在求解：

$$\max_w \int (\text{收益} - \text{风险} - \text{摩擦}) dt. \quad (7)$$

工程实现可被理解为 IPMO 的 Moreau 平滑 / Tikhonov 正则化 / 二阶动力学稳定极限。

5 等价性命题（可用于论文表述）

命题（结构等价性） 工程实现的方法在结构上等价于 IPMO 的两阶段框架。预测层被内生化为带不确定性修正的条件期望收益，决策层保持了原始 IPMO 的均值-方差-换手三项结构。区别仅在于将 L_1 型换手惩罚替换为光滑二次耗散项，使问题从非光滑凸规划转化为稳定的二阶控制系统。

直觉解释

论文构造的是一个“会交易的公式”，工程实现构造的是一个“不会炸的动力系统”。数学目标一致，但物理实现更加稳定。

6 理论母体：Stanford-Boyd 稳健框架与对偶逻辑

在量化建模层面，本策略解决了传统马科维茨（Markowitz）模型对输入参数的“病态敏感性（Sensitivity Pathology）”。

6.1 原始论文公理：椭圆不确定性集合（Uncertainty Set）

根据 Stephen Boyd (Stanford) 的核心公理，资产的真实收益 μ 并非点估计值，而是处于一个椭圆集合 $\mathcal{U}$ 中：

$$\mathcal{U} = \{\hat{\mu} + u \mid \|S^{-1/2}u\|_2 \leq \lambda\}$$

其中 S 为预测误差的协方差阵。原始论文证明，在这种约束下，最优权重 w 必须在最坏的情形（Worst-case）下依然保持正向期望。

6.2 权重的本质推导：正则化对偶（Regularization Duality）

这是理解“预测越差，表现越好”的数学钥匙。为了应对 0.0445 的噪声，我们需要展示从“最坏情况预测”到“权重正则化”的演变过程。

A. 鲁棒对偶变换：原始论文证明，将收益率 μ 设定在以 ρ 为半径的椭圆集合中时，原问题的对偶形式等价于在目标函数中增加一个基于权重的二阶惩罚项：

$$w^* = \operatorname{argmax}_w \left(\hat{\mu}^\top w - \gamma w^\top \Sigma w - \lambda \|\operatorname{diag}(\rho)w\|_2 \right)$$

B. “虚拟方差”与权重收缩效应：通过公式求导可发现稳健权重的本质：算法不再只看资产协方差 Σ ，而是强制在对角线上加上一层“虚拟风险屏障”。

$$w \propto \frac{\hat{\mu}}{\Sigma + \lambda \cdot \operatorname{diag}(\rho^2)}$$

当 $\rho = 0.0445$ （高误差）时，分母中的 ρ^2 项开始主导权重分配。即便某资产的预测收益 $\hat{\mu}$ 很高，如果其预测误差 ρ 同样巨大，分母的激增会强制压低其权重边界。这在数学上强制执行了“疑罪从无”。

7 Alpha 引擎：PCA 残差提取与归一化实现

我们的 Alpha 引擎基于统计收缩捕捉个股的特异性回归机会。

7.1 信号生成方程：剥离系统性因子

通过 PCA 提取第一主成分（Market Beta），获取纯粹的个股残差 ϵ ：

$$r_t = \beta F_{1,t} + \epsilon_t$$

7.2 核心改进：归一化算子与尺度缩放

引入异方差校准，这是导致“斜率下降但实战收益上升”的关键细节。

```
1 def get_normalized_predictions(df, lookback=40):
2     """
3     @param lookback: PCA 训练窗口（40天），平衡信号敏感度与稳定性
4     """
5     # 细节 A: 波动率算子（20日滚动）用于实现单位波动率收益归一化
6     vol = df[tickers].rolling(window=20).std()
7     preds = pd.DataFrame(index=df.index, columns=tickers)
8
9     for i in range(lookback, len(df)):
10        # 细节 B: PCA 降维提取（剔除市场共性趋势）
11        window = df[tickers].iloc[i-lookback:i]
12        pca = PCA(n_components=1)
13        factors = pca.fit_transform(window)
14
15        # 细节 C: 提取残差信号（统计套利核心）
16        residuals = window - pca.inverse_transform(factors)
17
18        # 细节 D: Scale Factor (0.05) 杠杆缩放
19        # 将原始信号转化为“单位波动率预期收益”，导致回归斜率降至 0.03
20        preds.iloc[i] = 0.05 * (residuals.iloc[-1] / vol.iloc[i])
21
22    return preds.shift(1) # 确保无未来函数
```

Listing 1: PCA 归一化预测逻辑实现

8 分配算法实现：二阶鲁棒性与动态误差学习

这是策略的执行层，核心在于通过预测误差 ρ 建立算法防御墙。

8.1 核心改进：收益收缩与风险膨胀

我们对优化参数进行数学重构：

- 收益收缩 (Revenue Shrinkage): $\tilde{\mu}_i = \frac{\mu_i}{1+\lambda\rho_i}$
- 风险膨胀 (Risk Inflation): $\tilde{\Sigma} = \Sigma + \lambda \cdot \text{diag}(\rho^2)$

8.2 稳健分配器实现

```
1 def solve_trading_allocator(mu, Sigma, rho, w_prev, kappa_vec, gamma=2.5,
2     lam=1.0):
3     """
4     @param rho: 动态学习到的预测误差（0.0445）
5     @param kappa_vec: 交易摩擦成本项（5bps）
6     """
7     n = len(mu)
8     # 注入二阶不确定性惩罚（对偶实现）
9     mu_tilde = mu / (1.0 + lam * rho)
10    Sigma_tilde = Sigma + lam * np.diag(rho**2) # 将 0.0445 注入对角线风险
11
12    w = cp.Variable(n)
13    z = w - w_prev
```

```

14 # 目标函数：期望鲁棒收益 - 风险惩罚 - L1 换手成本
15 # cp.abs(z) 产生的 L1 惩罚维持持仓“粘性”，过滤无效调仓
16 obj = cp.Maximize(mu_tilde @ w -
17                  gamma * cp.quad_form(w, Sigma_tilde) -
18                  cp.sum(cp.multiply(kappa_vec, cp.abs(z))))
19
20 constraints = [cp.sum(w) == 1, w >= -0.1, cp.norm(w, 1) <= 1.6]
21 prob = cp.Problem(obj, constraints)
22 prob.solve(solver=cp.CLARABEL)
23 return w.value

```

Listing 2: 基于 CVXPY 的稳健分配器

8.3 动态误差校准：Walk-forward Rho 机制

```

1 # 细节 E：指数移动平均（EMA）学习率 alpha=0.05
2 # 当市场剧变导致误差升至 0.0445 时，有效方差迅速膨胀，系统自动去杠杆防御
3 rho_wf = 0.95 * rho_wf + 0.05 * np.nanstd(p - a, axis=0)

```

Listing 3: 误差自适应学习

9 深度归因：Error (0.0445) 的决定性影响与真相

9.1 为什么预测越差，效果越好？

当 Error 达到 0.0445 时，它接管了权重分配逻辑：

- **概率防守**：在高噪声市场，追求高斜率本质上是在博弈随机噪音。
- **虚拟风险**：权重 w 与有效风险成反比。当 Error 极大时，有效风险 $\Sigma + \rho^2$ 爆炸，强制模型放弃高噪声资产。
- **内生低波倾向**：算法识别到高波资产预测误差过大，从而执行“智能避险”，将资金推向更确定性的区域。

9.2 核心思考

- **Arrogant 失败原因**：追求“预测精度”，但在真实噪声面前死于过拟合。
- **PCA Robust 成功原因**：接受“低精度”，转而管理“误差分布”。它赢在稳健执行而非精准猜测。

10 第二版本

11 实验设定与数据基础

- **股票池设定**：选取 $N = 20$ 只具有代表性的高流动性蓝筹股，涵盖科技 (AAPL, NVDA, MSFT, AVGO, ORCL, GOOGL, META, AMZN, TSLA)、金融 (JPM, BAC, GS, MS)、能源 (XOM, CVX)、医疗 (UNH, LLY, JNJ) 及消费 (WMT, COST)。
- **时间区间**：使用 2022–2025 年数据进行信号训练与模型校准，2025 年全年作为样本外 (Out-of-Sample) 验证区间。




Figure 1: strategy comparison




Figure 2: error distribution




Figure 3: Good prediction




Figure 4: Good prediction error

12 信号生成层：基于 PCA 的特异性 Alpha

12.1 因子剥离与残差计算 (Factor Extraction)

设 $W \in \mathbb{R}^{T \times N}$ 为窗口期内的收益率矩阵 ($T = 40$)。通过主成分分析提取协方差矩阵 Ω 的第一主成分特征向量 v_1 (满足 $\|v_1\|_2 = 1$)。定义市场投影 $\hat{W}$ 与特异性残差 ϵ 为：

$$\hat{W} = (W v_1) v_1^\top, \quad \epsilon = W - \hat{W} \quad (8)$$

12.2 多时域信号聚合与成交量流 (Conviction Flow)

聚合 $L \in \{3, 20, 90\}$ 时域信号，并引入成交量偏差对 Alpha 信心进行非线性调节：

$$S_{base} = \sum_L \left(\frac{\sum_{t=1}^L \epsilon_t}{\sigma_{20}} \right) - 0.5 \left(\frac{\sum_{t=1}^3 \epsilon_t}{\sigma_{10}} \right) \quad (9)$$

$$S_{raw} = S_{base} \cdot \tanh \left(\frac{Vol_{curr}}{Vol_{20}} - 1 \right) \quad (10)$$

13 风险管理：波动率过滤与动态不确定性

13.1 波动率过滤层 (Volatility Filtering Layer)

将信号按其特异性波动率倒数进行加权 (Volatility Scaling)，并进行 Z-Score 中性化：

$$\mu_{filt} = \frac{S_{raw}}{\sigma_{asset}}, \quad \sigma_{asset} = \sqrt{\text{Var}(\epsilon)} \quad (11)$$

$$\mu = \text{Z-Score}(\mu_{filt}) \quad (12)$$

13.2 核心参数：不确定性 ρ (Rho)

ρ_i 代表预测误差 $\epsilon_i = \mu_i - r_{t+1}$ 的标准差，衡量模型预测失效的程度。其通过指数平滑逻辑动态更新 ($H = 40, \alpha = 0.98$)：

$$\rho_{t+1} = \alpha \rho_t + (1 - \alpha) \max(\text{std}(\mu - r_{realized})_H, 0.01) \quad (13)$$

13.3 量纲对齐与非线性收缩逻辑

为了确保鲁棒性调整在数值实现上的稳定性，本策略放弃了传统的线性收益扣除法 (如 $\mu - \lambda \rho$)，转而采用非线性收缩因子 $(1 + \lambda \rho)^{-1}$ 对预期收益进行修正：

$$\tilde{\mu} = \frac{\mu}{1 + \lambda \rho} \quad (14)$$

该机制在工程实现与优化动力学上具有以下核心特性：

13.3.1 量纲一致性与参数含义

在原始均值-方差优化中，预期收益 μ 与预测误差标准差 ρ 的量纲均为 [收益率]，而协方差 Σ 的量纲为 [收益率]²。

- **量纲转换**：在 $\tilde{\mu}$ 的表达式中， $\lambda \rho$ 必须为无量纲数。因此， λ 的量纲被定义为 [1 / 收益率]，即信息比率 (Sharpe/IR) 的倒数阈值。




Figure 5: Simple Average

- **数值示例：** λ 扮演了置信度缩放因子的角色。例如，设定 $\lambda = 10$ ：
 - 若误差 $\rho = 0.02$ (2%)，分母为 $1 + 10 \times 0.02 = 1.2$ ，Alpha 施加约 83% 的收缩。
 - 若误差 $\rho = 0.10$ (10%)，分母为 $1 + 10 \times 0.1 = 2.0$ ，Alpha 强度直接减半。

13.3.2 自适应杠杆缩减 (Endogenous De-leveraging)

传统的线性扣除法在不确定性 ρ 极大时，可能导致预期收益 $\mu - \lambda\rho$ 变为负值，迫使优化器在模型失效时进行激进的反向交易（错误做空）。而分母惩罚机制实现了非线性压制：

- **完全信任极限：**当 $\rho \rightarrow 0$ 时， $\tilde{\mu} \rightarrow \mu$ ，模型完全采纳 Alpha 信号。
- **风险规避极限：**当 $\rho \rightarrow \infty$ 时， $\tilde{\mu} \rightarrow 0$ 。这确保了模型在完全不信任信号时，会自动切换至等权 (1/N) 或现金管理状态，而不是产生错误的激进头寸。

13.3.3 信噪比阈值与稳定性

该结构建立了一个隐性的信噪比门槛。由于收缩因子的存在，只有满足 $\frac{\mu}{\rho} > \lambda$ 逻辑特征的资产（即预期收益显著超过其预测误差）才能在优化中获得显著的正向权重分配。这在渐进意义上有效防止了由估计噪声引发的过度交易，显著提高了样本外表现的稳定性。

14 鲁棒均值-方差优化 (Robust MVO)

14.1 目标函数与解析等价转换

为处理估计误差，本策略将二阶锥规划 (SOCP) 简化为解析等价形式。为保证数值稳定性，对协方差矩阵 Σ 引入微小扰动 $\delta = 10^{-6}$ ：

$$\max_w \mathcal{L}(w) = \left(\frac{\mu}{1 + \lambda\rho} \right)^\top w - \gamma w^\top ((\Sigma + \delta I) + \lambda \text{diag}(\rho^2)) w \quad (15)$$




Figure 6: Parameter sweeping

14.2 优化硬约束 (Hard Constraints)

本系统采用了严格的**硬约束**机制，而非目标函数惩罚：

$$\text{s.t. } \mathbf{1}^\top w = 1 \quad (\text{全额投资}) \quad (16)$$

$$\|w\|_1 \leq 1.8 \quad (\text{杠杆约束}) \quad (17)$$

$$w_i \geq -0.10 \quad (\text{有限空头}) \quad (18)$$

$$\|w - w_{old}\|_1 \leq 0.25 \quad (\text{换手率硬约束}) \quad (19)$$

15 实证结论

回测显示，**Robust 模型**通过换手率硬约束和收益收缩机制，在 2025 年高波动环境中成功规避了由于 Alpha 信号失效导致的尾部风险，展现了优异的风险调整后收益，其夏普比率显著优于未校准的 Arrogant MVO。




Figure 7: Comparison

方法论	λ (鲁棒性)	信号过滤层	风险特征
自负模型 (Arrogant)	0	否	高贝塔依赖，回撤剧烈
鲁棒模型 (Robust)	10.0	是	风险自校准，夏普比率高
等权模型 (1/N)	N/A	否	收益平庸，极度分散

Table 2: 不同投资理念的参数与特征对比

16 参数对比总结

17 第三个版本

17.1 对称正则化与双重收缩机制 (Symmetric Regularization)

18 双重收缩机制 (Double-Shrinkage) 的数学机理

本策略未采用传统的后置权重缩放，而是通过在目标函数中植入双重惩罚项，构建了非线性的风险过滤机制：

$$\max_w \mathcal{L}(w) = \sum_{i=1}^n \underbrace{\left(\frac{\mu_i}{1 + \lambda \rho_i} \right) w_i}_{\text{进攻端：信号过滤}} - \underbrace{\gamma w^\top (\Sigma + \lambda \text{diag}(\rho^2)) w}_{\text{防御端：风险放大}} \quad (20)$$

- 信号降噪效应 (Alpha Filtering)**: 由于 μ 采用 Z-Score 标准化，其数值仅代表截面相对强度。通过分子端的收缩因子 $1/(1 + \lambda \rho)$ ，模型实现了对低信噪比信号的自动“消音”，防止了在市场动荡期盲目追逐虚假排名。
- 安全边际加载 (Risk Inflation)**: 在分母端引入 $\lambda \rho^2$ 实际上是为每项资产加载了特异性风险溢价 (Idiosyncratic Risk Premium)。这要求资产的预期回报必须能够覆盖“预测误差带来的虚拟方差”，从而在数学上强制执行了“疑罪从无”的防御逻辑。




Figure 8: Remove discounting factor

3. 非线性加速逃离 (Non-linear Risk Aversion): 权重 w 对误差 ρ 的灵敏度表现为:

$$w_i^* \propto \frac{\partial \mathcal{L}}{\partial \mu_i} \cdot \frac{1}{\partial^2 \mathcal{L} / \partial w_i^2} \approx \frac{\mu_i}{(1 + \lambda \rho_i)(\Sigma_{ii} + \lambda \rho_i^2)} \quad (21)$$

这种结构使得当预测不确定性 ρ 线性增长时，持仓权重会以接近立方级的速率迅速收缩。这种“加速逃离”机制是策略在回撤期表现稳健的核心原因。

19 walk forward analysis 滚动测试

»> Training Window: ('2021', '2022') (Optimizing for IR vs 1/N) Success: Optimal L=5.0, G=3.0 | Best IR: 0.7298

»> Training Window: ('2022', '2023') (Optimizing for IR vs 1/N) Success: Optimal L=15.0, G=8.0 | Best IR: 0.3385

»> Training Window: ('2023', '2024') (Optimizing for IR vs 1/N) Success: Optimal L=15.0, G=8.0 | Best IR: 0.8277

19.1 1. 核心理论：为何固定 λ 优于动态 WFA

前向走动优化 (Walk-Forward Optimization) 在实践中往往无法击败一个选择合理的固定 λ ，其根源在于“稳定性-适应性悖论” (Stability-Adaptation Paradox) 以及对 ** 认知不确定性 ** (Epistemic Uncertainty) 的处理差异。

19.1.1 1.1 λ 的哲学：认知风险 vs. 偶然风险

在模型中， λ 代表了对 Alpha 信号的“不信任程度”：

- 偶然不确定 (Aleatory Uncertainty): 市场内在的随机噪声，由协方差矩阵 Σ 刻画。
- 认知不确定 (Epistemic Uncertainty): 模型本身的局限性或市场逻辑发生结构性转变。

选择固定的 $\lambda = 10$ 构建了本杰明·格雷厄姆 (Benjamin Graham) 所提倡的“安全边际” (Margin of Safety)，即承认 PCA 模型有用但始终不完美。




Figure 9: walk forward




Figure 10: fix lamda gamma

19.1.2 1.2 WFA 失效的原因：策略滞后效应

WFA 将认知不确定性误认为具备“趋势性”，导致以下滞后效应：

1. **过度拟合**：在平稳行情中，WFA 会驱使 $\lambda \rightarrow 0$ （演变为“自大”的 MVO 模型）。
2. **鞭梢效应 (Whiplash Effect)**：当 λ 被调至最低时，市场机制往往发生突变，模型因缺乏保护而遭受重创。
3. **滞后修正**：模型在亏损后才调高 λ ，此时往往错过了随后的反弹。

19.1.3 1.3 林迪效应与低通滤波

固定的 $\lambda = 10$ 具有“林迪效应” (Lindy Effect)，即追求在长周期内“普遍正确”。它充当了一个**低通滤波器** (Low-Pass Filter)，忽略了参数估计中的高频噪声，专注于捕捉长期信号。

19.2 2. λ 的数学本质：基于信噪比 (SNR) 的闭式解

λ 在组合优化框架中并非单纯的超参数，从**贝叶斯收缩 (Bayesian Shrinkage)** 角度看，它存在理论上的最优闭式形式。

19.2.1 2.1 理论推导

若假设信号 μ 包含均值为 0、方差为 σ_μ^2 的真实 Alpha，而预测误差 ρ 的方差为 σ_ϵ^2 ，则最小化均方误差 (MSE) 的理论最优收缩系数 λ^* 可表达为：

$$\lambda^* = \frac{\sigma_\epsilon^2}{\sigma_\mu^2} = \frac{1}{SNR} \quad (22)$$

其中， SNR 为信噪比。

- 当 $SNR \rightarrow \infty$ 时， $\lambda \rightarrow 0$ （完全信任模型）。
- 当 $SNR \rightarrow 0$ 时， $\lambda \rightarrow \infty$ （完全不信任信号）。

19.2.2 2.2 WFA 的估计误差

WFA 之所以表现更差，是因为它试图用极不稳定的短期样本去估计 SNR 。金融数据的 SNR 极低且具有高度非平稳性。WFA 的估计误差 (Estimation Error) 往往超过了参数调整带来的收益。固定 $\lambda = 10$ 实际上捕捉了资产池在长周期内的**先验平均信噪比**。

19.2.3 2.3 与 James-Stein 收缩的关联

该逻辑与**James-Stein Estimator** 高度一致。Stein 证明了将所有估计值向均值收缩一部分，其统计效果优于直接使用观测值。在此模型中， λ 执行了关键的收缩强度控制：

$$w^* \propto (\Sigma + \lambda \text{diag}(\rho^2))^{-1} \mu_{shrink} \quad (23)$$

20 关于 λ 闭式解的哲学总结

实验结果表明，固定 $\lambda = 10$ 的优越性并非偶然。在前向走动分析中，由于 SNR 的样本估计量具有极大的波动性 (High Variance Estimator)，导致最优解的搜索陷入了“过拟合-滞后”循环。相比之下，固定 λ 避开了顺周期风险 (Pro-cyclical Risk-taking)，在样本外表现中展现出超越动态优化的鲁棒性。




Figure 11: Final comparison




Figure 12: Final Comparison

技术报告：集成投资组合与运动优化 (IPMO) 深度实现

Tiatian ZHANG

Abstract

本报告论证了在存在交易摩擦 (Transaction Costs) 的环境下，资产配置不应被视为一系列孤立的静止状态 (States)，而应被视为一个连续的**运动轨迹 (Trajectory)**。传统的“自大型”单期优化模型在面对 A 股高频波动时，常因过度交易导致净值被成本吞噬。IPMO 框架通过引入机器人运动规划中的多周期路径优化，结合“不确定性感知”权重，成功将日均换手率从 1.79 压制至 0.15，在保持 Alpha 捕捉能力的同时，实现了二阶执行效率的质变。

21 理论母体：从静止优化到动态轨迹规划

在量化执行层面，IPMO 解决了传统模型对当前信号过度反应的“鞭梢效应 (Whiplash Effect)”。

21.1 核心公理：多周期状态方程与半衰期对齐

根据 IPMO 的核心逻辑，决策变量不再是单一的 w_t ，而是在时间轴 H 上的权重向量序列：

$$\mathcal{W} = \{w_0, w_1, \dots, w_H\}$$

其中 w_0 是今日执行仓位，而 $w_{1:H}$ 是对未来路径的“预演”。

技术细节：设定 $H = 5$ 。该数值与 Alpha 信号的衰减特征高度对齐。经测算，底层信号的**半衰期 (Half-life)** 约为 3.5 个交易日，设定 $H = 5$ 的预测视界能完整覆盖信号从产生到枯竭的物理全过程，使优化器能平衡“当下的收益”与“未来的撤退轨迹”。

21.2 目标函数的分解：Alpha 收益、风险惩罚与运动平滑

优化目标被定义为多周期期望收益与轨迹平滑项的综合：

$$\text{Maximize } \sum_{t=0}^H \left(\mu_t^\top w_t - \gamma \|w_t\|_2^2 - \tau \|w_t - w_{t-1}\|_2^2 \right)$$

- γ (Risk Penalty): 对应代码中的 `gamma=20.0`，控制持仓集中度，构建“林迪效应”保护层。
- τ (Motion Smoothing): 对应代码中的 `tc_penalty=0.02`。它赋予组合“惯性”，防止在噪声中剧烈摆动。

22 关键工程实现：将理论转化为算力

22.1 不确定性感知 (Uncertainty-Awareness) 与低通滤波

论文指出，模型分歧即风险。我们通过多模型 ($m_{10} \dots m_{13}$) 的标准差 σ 来刻画认知不确定性 (Epistemic Uncertainty)。

数学实现：

$$\text{Confidence}(i) = \frac{1}{1 + \sigma_i}$$

在优化目标中，收益项被修改为 $\mu_i \times \text{Confidence}(i)$ 。

逻辑本质：这对应了 PDF 文档 14.1.3 中的核心哲学，即充当一个**低通滤波器 (Low-Pass Filter)**，忽略参数估计中的高频噪声，专注于捕捉长期稳健信号，实现了 Stanford-Boyd 框架下对“承认无知”的数学转化。

22.2 对称性子集筛选 (Symmetric Subset Selection)

为保证 5000+ 股票全市场的计算实时性，我们采用了“对称筛选”逻辑，这是解决“换手率为 0”问题的核心。

定义：优化变量空间 $\mathcal{S}$ 必须满足：

$$\mathcal{S} = \{i \mid i \in \text{Top-500 Alpha}\} \cup \{i \mid w_{t-1}(i) > 0\}$$

逻辑本质：确保优化器在寻找新机会 (Destination) 的同时，保留对旧仓位 (Origin) 的处分权，从而避免了因变量剔除导致的换手率锁定现象。

22.3 L_1 硬约束与 L_2 软惩罚的协同

- L_2 惩罚 (轨迹平滑)：利用 `tc_penalty` 确保路径在时间维度上的二阶可导性。
- L_1 硬约束 (换手上限)：基于 A 股执行摩擦，引入硬性流量控制：

$$\|w_0 - w_{prev}\|_1 \leq \text{daily_limit}$$

(第一天设为 1.0 用于建仓，后续严格限制在 0.15)。

23 实测结果：IPMO vs Naive vs Benchmark

在 2023-2025 年的回测数据中，展现了显著的性能分化：

- Naive 策略 (橙线)**：单期“自大”模型。虽有预测能力，但因缺乏运动规划，“速度”过快导致利润被手续费耗尽。
- IPMO 策略 (绿线)**：通过预判 $m50$ 的中长期演化并对齐 5 日半衰期，实现了“低换手、高捕获”。最终净值 **1.503**，平均换手稳定在 **0.153**。
- 林迪效应验证**：设定 $\text{gamma}=20.0$ 提供了极强的稳健性，在 2024 年底的市场突变中，回撤显著小于 Naive 策略，验证了“追求长周期普遍正确”的有效性。

24 结论：从决策精度向决策鲁棒性的升维

IPMO 的本质并非单纯追求“预测更准”，而是通过承认预测的不完美以及承认执行有代价，在数学上实现了从一阶预测精度向二阶决策鲁棒性的升维。实证证明，将调仓视为“带约束的连续运动轨迹”比将其视为“离散的静止点”更符合真实市场的博弈逻辑。

25 附录：核心配置与求解器说明

参数	建议值	物理含义与对齐逻辑
H	5	运动预测视界。与 Alpha 信号约 3.5 天的半衰期匹配。
gamma	20.0	风险厌恶系数。构建林迪效应保护层，防止过度集中。
tc_penalty	0.02	轨迹平滑系数。抑制无效的微小调仓运动。
max_turnover	0.15	物理执行限制。强制控制单日成本损耗。

求解器备注：本实现优先采用 **CLARABEL** 求解器。相比 OSQP (一阶 ADMM 算法)，CLARABEL 原生支持二阶锥规划 (SOCP)，在处理包含 L_1 范数的非光滑约束以及多周期大规模变量时，具有更优的数值稳定性和收敛精度。




Figure 13: Ipmo vs naive

26 深度关联：Stanford-Boyd 稳健优化与 IPMO 的血缘关系

IPMO 并非孤立的算法，其核心决策逻辑深植于 Stephen Boyd 教授的稳健优化理论。

- **哲学对齐**：Boyd 框架的核心是资产收益处于一个“椭圆不确定性集合”中。IPMO 通过代码中的 `uncert`（多模型标准差）实时刻画这个集合的大小。
- **从防御到步法**：如果说 Boyd 提供的是“盾”（在最坏情况下不崩盘），那么 IPMO 提供的是“步法”（在移动中保持平衡）。IPMO 将 Boyd 的静态稳健性扩展到了时间维度，利用多周期规划解决了稳健模型在动态调仓时的滞后性。
- **低通滤波的一致性**：PDF 文档中提到的固定 $\lambda = 10$ （空间滤波）与 IPMO 中的 `tc_penalty`（时间滤波）共同构成了一套完整的信噪比管理系统，确保策略只对具备“林迪效应”的稳健信号做出反应。